

Autenticação de Usuario Por Reconhecimento Facial

Jonathan Sebastian da Silva Moraes

Resumo — Nos últimos anos o uso do reconhecimento facial para autenticação de usuário vem se tornando bastante popular, levando isso em mente, este trabalho tem como objetivo realizar a comparação das técnicas Eigenfaces, Fisherfaces e Local Binary Pattern Histogram (LBPH) para verificar qual delas é mais eficiente durante o reconhecimento facial. Também serão apresentados como cada um dos algoritmos citados realizam o processo de reconhecimento facial e os dados estatísticos para cada um deles.

Palavras-Chave — Algoritmo, Reconhecimento Facial, Eficacia, Eigenfaces, Fisherfaces, LBPH

1 INTRODUÇÃO

Nos últimos anos o uso do reconhecimento facial para autenticação de usuário vem se tornando bastante popular devido ao crescimento do poder computacional [1]. Contudo, mesmo com um grande poder computacional existem diversos fatores que podem influenciar durante o reconhecimento como por exemplo o excesso ou a falta de iluminação, falta de qualidade nas imagens, gestos e posicionamento das faces.

Estudos revelam que os algoritmos Eigenfaces e Fisherfaces são sensíveis a variações de iluminação, ruídos e oclusão [2]. Entretanto, o LBPH é um algoritmo relativamente novo que comparado com o Eigenfaces e o Fisherfaces demonstra ser significativamente mais robusto em relação a iluminação e variação de poses [1].

O objetivo deste estudo foi realizar a avaliação dos algoritmos Eigenfaces, Fisherfaces e LBPH disponibilizados pelo OpenCV, para então assim poder selecionar qual o melhor deles para ser utilizado em um sistema de autenticação de usuario por reconhecimento facial.

As hipóteses eram:

H0: Os algoritmos não possuem diferença durante o reconhecimento facial.

H1: Pelo menos 1 dos algoritmos possui diferença durante o reconhecimento facial.

2 METODOS UTILIZADOS

Nesta seção é explicado como que funciona cada um dos algoritmos utilizados para resolver o problema de reconhecimento facial.

2.1 Eigenfaces

O algoritmo eigenfaces implementa o Principal Component Analysis (PCA) [3]. PCA é um método utilizado para reduzir a dimensionalidade [4]. Após a redução da dimensionalidade e extraída a face média a partir de todas as imagens de uma determinada pessoa. A face média é responsável por mostrar quais são os desvios e quais as variações da imagem.

A estratégia deste método é extrair os traços característicos da face representando a face em questão como uma combinação linear das chamadas 'eigenfaces' obtidas pelo processo de extração de características. Os principais componentes das faces do conjunto de treinamento são calculados. O reconhecimento é alcançado usando a projeção da face no espaço formado pelos eigenfaces. É realizada uma comparação com base na distância euclidiana dos eigenvectors dos eigenfaces e do eigenface da imagem em questão, se esta distância for pequena o bastante, a pessoa é identificada [5].

Para realizar o cálculo do funcionamento do algoritmo, considere ter um conjunto de imagens de rosto que podem ser representados em um espaço g-dimensional. O PCA visa obter um subespaço h-dimensional tendo vetores de base que correspondem as direções de variação máxima do espaço g-

• M. S. S. Jonathan Acadêmico em Ciência da Computação, Universidade Tiradentes, Aracaju, Brasil. E-mail: jonathan.ssm.dev@outlook.com.

dimensional. Logo, h é muito menor que g . O subespaço original é mapeado dentro do menor por meio de uma transformação linear. As imagens de treinamento L são normalizadas e depois subtraídas da imagem média calculada para obter a média central das imagens. Seja W uma matriz contendo a média central das imagens de treinamento W_i onde $i = 1, 2, 3, \dots, L$. De W , obtemos a matriz de covariância D , onde:

$$D = WW^T$$

A matriz de covariância D pode ser muito grande e foi provado matematicamente que podemos usar $D = W^T W$ em vez disso. Então de D , obtemos os eigenvectors Θ_i e seus eigenvalues associados λ_i . Em seguida, uma matriz E é formada composta por eigenvectors associados aos maiores eigenvalues para obtermos:

$$Z_i = E^T w_i \text{ onde, } i = 1, 2, \dots, L$$

Z_i são os novos vetores no novo subespaço dimensional inferior. Portanto, as imagens são projetadas desta forma no novo subespaço. Em um teste a imagem é tratada da mesma maneira até projetada no mesmo subespaço. Então é utilizada a distância medida para testar a semelhança entre o teste e as imagens de treinamento [4].




Fig. 1. Um exemplo do funcionamento do Eigenfaces

Fonte:
<https://onionesquereality.files.wordpress.com/2009/02/eigenfaces-reconstruction.jpg>

2.2 Fisherfaces

Para o algoritmo fisherfaces utilize os termos fisherfaces e LDA de forma intercambiável, Linear Discriminant Analysis (LDA) [4, 6, 7] tenta diferenciar

entre as classes em vez de tentar apresentar os dados. Portanto, LDA se preocupa em obter vetores para a discriminação das classes. São definidas duas matrizes de dispersão:

$$S_w = \sum_{j=1}^R \sum_{i=1}^{M_j} (x_i^j - \mu_j)(x_i^j - \mu_j)^T$$

$$S_b = \sum_{j=1}^R (\mu_j - \mu)(\mu_j - \mu)^T$$

A primeira é chamada de matriz de dispersão dentro da classe enquanto a segunda é chamada de dispersão entre classes matrizes. j denota a classe enquanto i denota o número da imagem. μ_j é a medida da classe j enquanto μ é a média de todas as classes. M_j é o número de imagens da classe j e R é o número de classes. O algoritmo visa maximizar a matriz entre classes enquanto minimiza a matriz dentro da classe isto pode ser feito maximizando a proporção $(\det | S_b | / \det | S_w |)$. Como no PCA nos temos a projeção da matriz G . Esta matriz é usada para maximizar a proporção mencionada quando as colunas são eigenvectors de $S_w^{-1} S_b$. Um problema surge quando S_w se torna singular. [4, 7, 8] sugerem utilizar um espaço intermediário – antes de transformar o espaço original no espaço final – que é o espaço PCA. Em outras palavras, o espaço original é

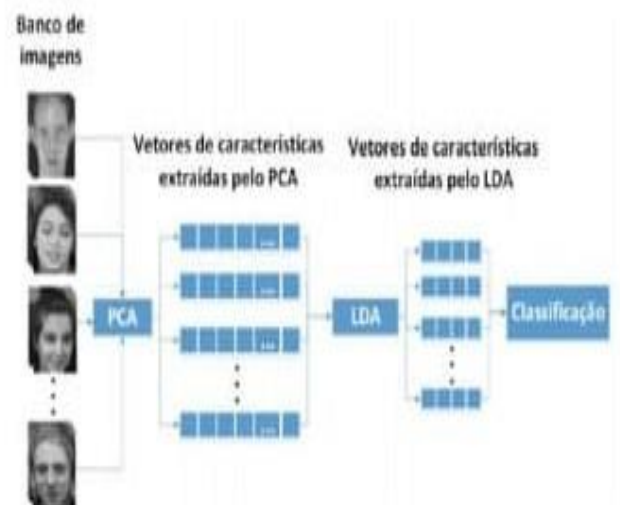


Fig. 2. Um exemplo do funcionamento do Fisherfaces

Fonte:
<https://repositorio.ufu.br/bitstream/123456789/22158/3/ReconhecimentoFacialAlgoritmos.pdf>

projetado no espaço PCA antes de ser projetado no espaço LDA.

2.3 Local Binary Pattern Histogram (LBPH)

O Local Binary Pattern Histogram (LBPH), proposto em 2006 [9, 10] é um algoritmo utilizado para reconhecimento facial baseado no operador binário local [10, 11]. Segundo [10, 12] o LBPH é um algoritmo muito popular e amplamente utilizado, devido ao seu poder discriminativo e a sua simplicidade de computação.

O LBPH funciona da seguinte forma, é utilizada uma imagem $N \times M$ e é dividido em regiões. O mesmo tamanho é o ideal, na largura e na altura, resultando em regiões $m \times m$. Em cada região, o operador binário local é utilizado. Quando aplicado em imagens, este operador, compara um pixel a seus oito pixels vizinhos mais próximos. A comparação verifica se o valor do pixel vizinho é mais alto que o pixel central, retornando um valor de '1' neste caso. Em qualquer outro caso, um valor '0' é retornado. Aplicando este processo a todos os 8 vizinhos, 8 valores binários são derivados. Um número binário de 8 bits é formado ao fundir estes valores. O número binário obtido pode ser traduzido em um valor decimal, chamado de valor LBP do pixel,




Fig. 3. Exemplo do operador LBP

em um intervalo entre 0-255 [10]. A Figura 3 demonstra como esta operação é realizada. O processo é executado para cada pixel na região.

O histograma para a região atual é então criado, calculando o número de aparecimentos de todos os valores LBP nesta região. Através deste processo, o histograma para cada região consiste em 256 bins. Este processo é representado por meio da seguinte equação:

$$H_i = \sum_{x,y} I\{LBP(J(x,y)) = i\}, i = 0, \dots, 255(1)$$

Onde H_i é o bin do valor i , $J(x, y)$ é o pixel (x, y) da imagem e I é um operador condicional, retornando '1' se a afirmação é verdadeira ou '0' se a afirmação for falsa. Uma vez que os histogramas para todas as regiões foram calculados, um único histograma é criado unificando todos os histogramas de cada seção. Este histograma final conterá $256 * m * m$ bins e é definido como o vetor de recursos da imagem [10].

Para prosseguir com o reconhecimento facial, um banco de dados (bd) de vetores correspondentes às imagens de rostos são necessários. A distância entre os diferentes vetores de características são então calculados. A imagem que corresponde ao vetor de recurso com a distância mais próxima é retornado como a melhor correspondência para a imagem testada. Isso pode ser derivado da seguinte equação:

$$(M, Index) = \min(dst[bd\ size])$$

Onde dst é a matriz das distâncias calculadas e \min é a função que retorna o valor mínimo (M) da matriz e o valor do índice ($Index$), um limite também é aplicado para excluir faces que não correspondem a qualquer um dos rostos no banco de dados. Se M for menor que o Threshold o $Index$ é uma correspondência, senão o $Index$ não é uma correspondência [10].

3 METODOLOGIA

3.1 Hardware e Sistema Operacional Utilizado

Durante todo o desenvolvimento do trabalho foi utilizado uma máquina com uma Placa-Mãe Gigabyte X99-UltraGaming, Processador Intel(R) Core (TM) i7-6800K 3.40Ghz, Memória Hyperx 16GB 2666mhz e uma GPU Gigabyte Xtreme Gaming 8GB. O Sistema Operacional utilizado foi o Windows 10.

3.2 Ferramentas e Fases do Processo

Antes de iniciar o processo de testes, foi preciso definir quais ferramentas seriam utilizadas. A linguagem utilizada durante todo o processo de detecção de faces, treinamento dos algoritmos, testes estatísticos e reconhecimento facial foi Python 3.8.2 em conjunto com as bibliotecas Flask 1.1.2, click 7.1.2, itsdangerous 1.1.0, Jinja2 2.11.2, MarkupSafe 1.1.1, pip 20.2.4, setuptools 50.3.2, Werkzeug 1.0.1, Flask-Cors 3.0.9, numpy 1.19.3, opencv-contrib-python

4.3.0.38 e Pillow 8.0.1. Para a implementação da página web responsável pela chamada da API desenvolvida em Python para a realização da autenticação por reconhecimento facial, foi utilizado o framework Angular.

O Python foi escolhido por ser uma linguagem com uma comunidade bastante ativa e por ter inúmeras bibliotecas que facilitam o processo de desenvolvimento, sendo uma delas o OpenCV que apresenta inúmeras ferramentas na área de processamento de imagem, com algoritmos (Eigenfaces, Fisherfaces e LBPH) e funções otimizadas.

Para que seja possível realizar o reconhecimento facial é necessário realizar a coleta das imagens, podendo ser um dataset de imagens, também é necessário realizar a detecção de faces nas imagens para que o dataset possua apenas imagens de faces, depois do dataset preparado é necessário realizar o treinamento do algoritmo, após a finalização do treinamento é realizado o reconhecimento facial que pode ser em tempo real ou utilizando um dataset de imagens de teste. Estas etapas serão detalhadas subseções seguintes.

Os algoritmos utilizados para treinamento e reconhecimento facial em todo o projeto foi o Eigenfaces o Fisherfaces e o Local Binary Pattern Histogram (LBPH). As implementações destes algoritmos na biblioteca OpenCV são bem completas e de fácil uso na linguagem Python.

O processo de aprendizado utilizado foi o supervisionado, onde as estruturas das imagens possuem um (id) para cada pessoa, seguido pelas variações das poses de cada pessoa.




Fig. 4. Estrutura das imagens com seus identificadores e variações de poses

3.2.1 Dataset

O dataset utilizado para a realização dos testes foi o Yalefaces. O Yalefaces é composto por imagens que retratam diferentes indivíduos em diferentes poses sob condições de iluminação controlada [13] e possui 165 imagens de rosto.

3.2.2 Detecção Facial

Segundo [14] considera-se a primeira etapa para o reconhecimento facial, a detecção de características em uma determinada imagem ou frame de vídeo.

Para a detecção das faces foi utilizado a classe CascadeClassifier do OpenCV que utiliza como parâmetro um arquivo .xml, neste trabalho o arquivo utilizado foi o haarcascade_frontalface_default.xml.

3.2.3 Reconhecimento Facial

Segundo [15] reconhecimento facial é o processo de identificação de pessoas em uma imagem ou frame de vídeo. O mesmo autor ainda diz que o reconhecimento facial consiste em duas técnicas:

Características geométricas, que consiste em calcular um conjunto de características geométricas, como largura e comprimento do nariz, posição da boca e formato do queixo etc., da imagem do rosto que queremos reconhecer. Estes recursos então correspondem as características de uma pessoa conhecida. Uma métrica adequada quanto a distância euclidiana pode ser usada para encontrar a correspondência mais próxima.

Comparação de modelos, onde a base da estratégia é extrair regiões faciais inteiras e comparalas com as imagens de pessoas conhecidas armazenadas. Novamente a distância euclidiana pode ser utilizada para encontrar a correspondência mais próxima. No entanto existem métodos muito melhores para a comparação de modelos, como por exemplo o PCA.

4 RESULTADOS

As métricas utilizadas para a avaliação dos algoritmos foram, a porcentagem de acerto, o nível de confiança, o tempo de treinamento e o tempo de reconhecimento, para avaliar os algoritmos primeiramente foi realizada a coleta dos dados de todas as métricas sem alteração nos parâmetros dos

algoritmos, após a primeira coleta de dados foram re-

Eigenfaces				
Acerto	Confiança	Parametro	T. Treinamento	T. Reconhecimento
70.37%	6304.09	Padrão	9.09s	0.90s
7.40%	1461.72	2000	9.05s	0.81s
25.92%	2789.30	4000	9.23s	0.85s
44.44%	4027.05	8000	9.24s	0.86s
55.55%	3571.88	40,8000	4.04s	0.64s
62.96%	3020.27	15,8000	2.87s	0.56s

Fig. 5. Resultados dos testes do Eigenfaces

alizados outros 4 testes variando os parâmetros de cada algoritmo.

4.1 Eigenfaces

Como pode ser analisado na Figura 5, o algoritmo Eigenfaces possui uma taxa de confiança extremamente ruim, suas taxas de acerto também não são muito boas, isso acontece porque o algoritmo possui uma alta sensibilidade a variações de iluminação [2], como pode ser visto na tabela da Figura 5 a maior taxa de acerto do algoritmo foi de 70.37% porem com um nível de confiança ruim, ao realizar a variação dos parâmetros nota-se que ao aumentar o threshold a taxa de acerto auemnta, entretando o nível de confiança piora. Alem de variar o threshold foi também testado a variação do num_components, onde foi possível obter a melhor taxa de acerto em relação ao nível de confiança, que foi 62.96% de acerto com um nível de confiança de 3020.27. Ao analisar estes dados pode ser concluído que este não seria um algoritmo ideal para realizar uma autenticação de usuário por reconhecimento facial, pois ele precisa de um threshold muito alto para conseguir reconhecer os rostos, o que gera um nível de confiança baixo, que ocasiona reconhecimentos equivocados. Também pode ser notado que ao não passar o número de componentes e utilizar o padrão do próprio algoritmo o tempo de treinamento aumenta consideravelmente.

A análise do nível de confiança em relação ao número de componentes utilizados, pode ser observada na Figura 6, onde foi gerado um gráfico demonstrativo dos dados utilizando de 0-200 componentes.




Fig. 6. Relação entre número de componentes e o nível de confiança

4.2 Fisherfaces

Em relação ao algoritmo Eigenfaces o Fisherfaces conseguiu obter melhores taxas de acerto, melhores níveis de confiança e melhores tempos de treinamento.

Fisherfaces				
Acerto	Confiança	Parametro	T. Treinamento	T. Reconhecimento
70.37%	1592.78	Padrão	2.76s	0.58s
48.14%	1124.29	2000	2.80s	0.50s
70.37%	1592.78	4000	2.77s	0.58s
70.37%	1592.78	8000	2.77s	0.59s
77.77%	509.08	3, 2000	2.23s	0.56s
48.14%	255.56	2, 2000	2.20s	0.54s

Fig. 7. Resultados dos testes do Fisherfaces

Ao realizar a análise dos dados obtidos através dos testes do algoritmo Fisherfaces, pode ser observado que sua maior taxa de acerto foi de 77.77% com um nível de confiança de 509.28, também foi notado que a variação do threshold não impacta tanto nos níveis de confiança, entretando a taxa de acerto é bastante afetada caso o threshold seja muito baixo. O tempo de treinamento também não é muito afetado quando

não passado o numero de componentes, como acontece com o Eigenfaces, as taxas de acerto e níveis de confiança se mantiveram estáveis mesmo com a variação do threshold, porem ao variar o numero de componentes, tanto o nível de confiança quanto a taxa de acerto são bastante afetadas, ao utilizar 3 componentes e 2000 de threshold a taxa de acerto foi de 77.77% e o nível de confiança 509.08, e ao diminuir apenas 1 componente, utilizando assim apenas 2, a taxa de acerto caiu 29.63% porem o nível de confiança melhorou, ou seja, no algoritmo Fisherfaces quanto maior o número de componentes melhor é a taxa de acerto, porem, ao mesmo tempo que a taxa de acerto sobe o nível de confiança diminui.

4.3 Local Binary Pattern Histogram (LBPH)

O LBPH possui cinco parâmetros que podem ser alterados, são eles, o radius, neighbors, grid_x, grid_y e o threshold. Durante o teste do LBPH também foi realizado o teste inicial sem alteração nos parâmetros, para analisar como o algoritmo se comporta sem modificações e comparar com os dados variando os parâmetros. A Figura 8 a seguir mostra o resultado dos testes.

LBPH				
Acerto	Confiança	Parametro	T. Treinamento	T. Reconhecimento
62.96%	12.58	Padrão	1.25s	1.09s
62.96%	12.58	2000	1.25s	0.95s
62.96%	12.58	4000	1.27s	1.03s
62.96%	12.58	8000	1.24s	0.93s
59.25%	0.92	2, 2, 7, 7, 200	0.22s	0.54s
59.25%	0.31	1, 1, 7, 7, 18	0.14s	0.55s

Fig. 8. Resulta dos testes do algoritmo LBPH

Podemos perceber que a taxa de acerto do LBPH é menor em relação ao Fisherfaces, porem seus níveis de confiança são bem melhores, a maior taxa de acerto do Fisherfaces foi de 77.77% e a maior do LBPH foi de 62.96%, entretando o nível de confiança em relação a melhor taxa de acerto do LBPH foi de 12.58 enquanto a do Fisherfaces foi de 509.08.

No LBPH pode ser notado que a não utilização dos parâmetros impactam um pouco no tempo de treinamento e no tempo de reconhecimento, também pode ser notado que a taxa de acerto e o nível de confiança não alteram ao variar apenas o threshold, estes resultados so começam a mudar quando são variados os valores do radius, neighbors, grid_x, grid_y juntamente com o threshold, nota-se que quando alterados esses parâmetros a taxa de acerto diminuiu 3.71% porem o nível de confiança melhorou consideravelmente. Ao diminuir o valor do radius, do neighbors e do threshold, pode ser notado que o nível de confiança obteve uma melhora sem alterar a taxa de acerto, mantendo também um baixo tempo de treinamento e de reconhecimento.

4 CONCLUSÃO

Três algoritmos foram avaliados para verificar se eles possuíam diferenças durante o reconhecimento facial, a partir das análises concluímos que a hipótese H0 foi refutada pois os algoritmos demonstraram ter resultados diferentes durante o processo de reconhecimento facial, o algoritmo Fisherfaces obteve a melhor taxa de acerto entre os três, com uma taxa de 77.77%, entretando o algoritmo Local Binary Pattern Histogram obteve o melhor nível de confiança que foi 0.31. Como o objetivo do trabalho era avaliar qual dos três algoritmos iria obter o melhor resultado durante o reconhecimento facial para autenticação de usuario, podemos concluir que a melhor escolha seria o LBPH, o mesmo não obteve a melhor taxa de acerto, mas obteve a melhor taxa de acerto em relação ao nível de confiança, por isso a melhor escolha seria o LBPH, em um sistema de autenticação de usuário, um nível de confiança muito baixo pode gerar a autenticações erradas no sistema.

REFERÊNCIAS

- [1] A. Özdemir and M. M. Özben, "A survey on comparison of face recognition algorithms," *2014 IEEE 8th International Conference on Application of Information and Communication Technologies (AICT)*, Astana, 2014, pp. 1-3, doi: 10.1109/AICT.2014.7035956.
- [2] N. Hegde, S. Preetha and S. Bhagwat, "Facial Expression Classifier Using Better Technique: FisherFace Algorithm," *2018 International Conference on Advances in Computing, Communications and Informatics (ICACCI)*, Bangalore, 2018, pp. 604-610, doi: 10.1109/ICACCI.2018.8554499.
- [3] M. Turk and A. Pentland, Eigenfaces for recognition, *J Cogn Neurosci* 3 (1991), 71–86. W.

- [4] M. Sharkas and M. A. Elenien, "Eigenfaces vs. fisherfaces vs. ICA for face recognition; a comparative study," 2008 9th International Conference on Signal Processing, Beijing, 2008, pp. 914-919, doi: 10.1109/ICOSP.2008.4697276.
- [5] M.üge Çarıkçı, Figen Özen, A Face Recognition System Based on Eigenfaces Method, *Procedia Technology*, Volume 1, 2012, Pages 118-123, ISSN 2212-0173, <https://doi.org/10.1016/j.protcy.2012.02.023>. (<http://www.sciencedirect.com/science/article/pii/S2212017312000242>)
- [6] Zhao, R. Chellappa, A. Krishnaswamy, Discriminant analysis of principal components for face recognition, *Proc Third IEEE Int Conf Automatic Face and Gesture Recogn*, Nara, Japan, 14–16 April, 1998, pp. 336–341.
- [7] P. Belhumeur, J. Hespanha, and D. Kriegman, Eigenfaces vs. fisherfaces: Recognition using class specific linear projection, *Proc Fourth Eur Conf Computer Vision*, Vol. 1, 14–18 April 1996, Cambridge, UK, pp. 45–58.
- [8] D. Swets and J. Weng, "Using Discriminant Eigenfeatures for Image Retrieval," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 18, pp. 831-836, 1996.
- [9] H. A. Ahonen, T. and M. Pietikinen, "Face description with local binary patterns," *IEEE Trans. Pattern Analysis and Machine Intelligence*, vol. 28, no. 12, pp. 2037–2041, 2006.
- [10] N. Stekas and D. Van Den Heuvel, "Face Recognition Using Local Binary Patterns Histograms (LBPH) on an FPGA-Based System on Chip (SoC)," 2016 IEEE International Parallel and Distributed Processing Symposium Workshops (IPDPSW), Chicago, IL, 2016, pp. 300-304, doi: 10.1109/IPDPSW.2016.67.
- [11] P. M. Ojala, T. and D. Harwood, "A comparative study of texture measures with classification based on feature distributions," *Pattern Recognition*, vol. 19, no. 3, pp. 51–59, 1996.
- [12] M. Pietikinen, "Local Binary Patterns," vol. 5, no. 3, p. 9775, 2010.
- [13] Damianou, Andreas (2015) *Deep Gaussian Processes and Variational Propagation of Uncertainty*. PhD thesis, University of Sheffield.
- [14] Santana, L. M. Q. de, & Rocha, F. G. (2015). Processo de detecção Facial utilizando Viola; Jones. *Interfaces Científicas - Exatas E Tecnológicas*, 1(1), 35-40. <https://doi.org/10.17564/2359-4942.2015v1n1p35-40>
- [15] Análisis Comparativo de Los Algoritmos Fisherfaces Y LBPH Para El Reconocimiento Facial En Diferentes Condiciones de Iluminación Y Poes, TACNA – 2015. <http://repositorio.unibg.edu.pe/handle/UNIBG/2479>

Primeiro A. Autor Todas as biografias devem limitar-se a um parágrafo que consiste nos seguintes: lista de diplomas sequencialmente ordenados, incluindo anos alcançados; locais de contratação sequencialmente ordenados concluindo com o emprego atual; associação com quaisquer revistas oficiais ou conferências; grandes realizações profissionais e/ou acadêmicas, ou seja, melhores prêmios de papel, bolsas de pesquisa, etc.; quaisquer informações de publicação (número de artigos e títulos de livros publicados); interesses atuais de pesquisa; associação com qualquer associação profissional e profissional. As informações de adesão ao autor, por exemplo, são membros do IEEE e da IEEE Computer Society, se aplicável, é notada no final da biografia.

Segundo B. Autor Jr. biografia aparece aqui.

Terceira biografia de C. Autor aparece aqui.